

Kodowanie i kompresja danych 2023

Laboratorium nr 3 i 4 (na ocenę)

Zadanie na laboratorium

Napisz program kodujący i program dekodujący dany plik wejściowy na dany plik wyjściowy. Program kodujący powinien dodatkowo na koniec zwrócić na ekran odpowiednio entropię kodowanych danych, średnią długość kodowania i stopień kompresji. Alfabetem danych pierwotnych są bajty (8-bitowe znaki).

Program może być napisany w dowolnym języku programowania, ale jego czas działania dla testów z poprzedniej listy nie powinien przekraczać 30 sekund. Programy powinny być wywoływane z linii poleceń z podanymi nazwami plików jako argumentami wywołania.

Należy wybrać jeden z wariantów:

Ocena 3 Programy mają używać klasycznego kodowania Huffmana i w czasie kompresji dodawać odpowiednio zapamiętany słownik umożliwiający dekompresję.

Ocena 4 Programy mają używać dynamicznych kodów Huffmana.

Ocena 5 Programy mają używać adaptacyjnego kodowania arytmetycznego ze skalowaniem.

Ocena programów może być przez prowadzącego laboratorium podwyższona o 0.5 za jakość wykonania.

Zadania przygotowawcze do kolokwium

Zadanie 1

Skonstruuj kod Huffmana dla następującego ciągu prawdopodobieństw występowania symboli: $P(a) = 0.1$, $P(b) = 0.1$, $P(c) = 0.15$, $P(d) = 0.25$ i $P(e) = 0.4$.

Zadanie 2

Prześledzić jaką mają postać kody Huffmana dla:

1. k jednakowo prawdopodobnych symboli;
2. k symboli takich, że $P(a_i) = \frac{1}{2^i}$, dla $i \in \{1, \dots, k-1\}$, i $P(a_k) = \frac{1}{2^{k-1}}$.

Zadanie 3

W algorytmie Huffmana można w zależności od kolejności kodowania symboli z jednakowym prawdopodobieństwem, uzyskać różne (nieizomorficzne) drzewa kodów. Jaką strategię należałoby użyć, aby odchylenie standardowe długości kodów było jak najmniejsze? (Oczekiwana długość kodów będzie oczywiście jednakowa.)

Zadanie 4

Znajdź sytuacje, w których średnia długość kodu Huffmana jest

1. równa entropii;
2. przybliża się do entropii plus jeden (jest jak największa).

Zadanie 5

Prześledź działanie dynamicznego kodowania Huffmana. Wybierz w tym celu kilka losowych słów o długości 8, utworzonych z 4 literowego alfabetu $\{a, b, c, d\}$.

Zadanie 6

Dla danych z Zadania 1 skonstruuj 4-o i 5-o bitowe kody Tunstalla. Porównaj średnią ilość bitów na jeden symbol wejściowy tych kodów i kodu Huffmana.

Zadanie 7

Dla kodu o następujących prawdopodobieństwach wystąpienia: $P(a) = 0.2$, $P(b) = 0.3$ i $P(c) = 0.5$, znajdź znacznik w kodowaniu arytmetycznym dla ciągu *aabcba*. Następnie odkoduj ciąg o długości 10 i znaczniku 0.63215699.

Zadanie 8

Napisz pseudo-kod kodowania i dekodowania arytmetycznego ze skalowaniem. Prześledź pracę obu algorytmów dla danych z poprzedniego zadania.